

TP Final — Infra para Ciencia de Datos



Entrega: dom 15/11, 23:59



Presentación: jue 19/11

1 Objetivo

Construir un pipeline de datos **end-to-end** sobre **una API pública**, con arquitectura medallion. Orquestrarlo con **Airflow**, guardarlo en **PostgreSQL** y mostrar un **dashboard sobre Gold** (todo containerizado).

2 Cómo se evalúa

1 Entrega y funcionamiento

Un `docker compose up` que levante todo (base, Airflow y dashboard), que el pipeline **empiece a correr solo**, sin activar DAGs a mano ni crear schemas manualmente: Bronze corre al levantar el stack y, cuando termina, dispara Silver y después Gold.

2 Cumplir la consigna

Las versiones y tecnologías pedidas: **Airflow 3.1.5** (imagen `apache/airflow:3.1.5`), arquitectura **Medallion** (Bronze → Silver → Gold) y **SQL** para las transformaciones, **dashboard** sobre las tablas Gold (**Star o Snowflake**), y **README del grupo**: integrantes y usuarios de GitHub, API elegida, modelo de datos, cómo levantarlo, y usuario y contraseña de Airflow.

3 Trabajo colaborativo en git

Commits de **distintos integrantes**, repartidos en el tiempo.

4 Presentación final

Tiempos y formas: 7 a 10 minutos, dinámica y clara. Qué problema eligieron, cómo lo resolvieron y a qué resultado llegaron.

Adicional, para la nota individual:

5 Participación durante la cursada

Las entregas de cada clase, en tu PR.

3 Cómo se entrega

1. **Usen el número de grupo** que ya tienen asignado (`G01` , `G02` ...). Va en la rama, en la carpeta y en el título del PR.
2. Creen la rama `tpfinal/G<NN>` desde `main` , y la carpeta `TpFinal/grupos/G<NN>/` .
3. Abran un **PR** contra `main` , con título `TP Final - G<NN> - <API>` . En el cuerpo: integrantes (nombre + usuario de GitHub), API elegida e idea para Gold.

4. Trabajen en esa rama: **cada push actualiza el PR solo**.
5. **Entrega: domingo 15 de noviembre, 23:59** (hora Argentina). Vale **lo que esté en la rama** en ese momento: no hay que apretar ningún botón.

El `.env` del grupo **sí va al repo**, a propósito: así el stack levanta con un solo comando. Son credenciales de juguete (`admin/admin`). Una API key real no va ahí: se pasa como variable del host y el `.env` la lee con `${MI_API_KEY}` .

4 La presentación final

Jueves 19 de noviembre de 2026 · remota, por videollamada · 7 a 10 minutos por grupo, con el dashboard corriendo. Muestren la idea del proyecto y el pipeline funcionando. Después, una ronda corta de **preguntas**.

Cómo contarlos

La presentación tiene tres partes: **problema** → **enfoque** → **resultados**.

- **Problema:** el problema que seleccionaron, y por qué vale la pena resolverlo.
- **Enfoque:** qué y cómo hicieron para resolverlo — los datos, el pipeline y las decisiones que tomaron.
- **Resultados:** los resultados que obtuvieron — el dashboard y las conclusiones.

Los 7 a 10 minutos

Una distribución posible, no obligatoria:

1 a 2 min	3 a 4 min	2 a 3 min
el problema que seleccionaron	qué y cómo hicieron para resolverlo	los resultados que obtuvieron (dashboard y conclusiones)

Formato libre, pero descargable: la presentación **se sube al campus**, así que tiene que quedar en **PDF o PPT**. **Entre 5 y 10 diapositivas**. No va al repo ni entra en el corte del 15/11: se puede subir hasta el momento de presentar.

Tips

- Que sea **dinámico**.
- No hace falta que hablen todos, pero **todos tienen que estar listos para responder**.
- **Cámara prendida** durante la exposición.

5 Fuentes posibles

Elijan **una**. Todas se actualizan al menos cada hora. Pueden repetir API entre grupos, o proponer otra consultando con el docente.

No valen APIs de crypto ni de exchanges: CoinGecko es el ejemplo que usamos en clase.

💡 Las ideas por capa son **orientativas**, no requisitos.

01 Open-Meteo — Clima

open-meteo.com

Sin auth, sin límite

Cada hora

BRONZE Clima actual + forecast 7 días para N ciudades: temperatura, lluvia, humedad, viento.

SILVER Normalizar unidades (°C, km/h), separar forecast de medición real, sensación térmica.

GOLD `fact_clima_diario`, `dim_ciudad`, `dim_tiempo`. Dashboard: comparación entre ciudades, alertas de temperatura extrema.

02 OpenWeatherMap — Clima

api.openweathermap.org

API key gratis

Cada 10 min

BRONZE Clima actual + pronóstico 5 días para ciudades configuradas.

SILVER Parsear JSON anidado, extraer condiciones (nublado, lluvia, despejado), UTC → local.

GOLD `fact_pronostico_vs_real`, `dim_condicion_climatica`. Dashboard: precisión del pronóstico, patrones por estación.

03 OpenAQ — Calidad del aire

api.openaq.org/v2

Sin auth

Cada hora

BRONZE Mediciones de PM2.5, PM10, CO, NO2, O3 por estación de monitoreo global.

SILVER Filtrar mediciones inválidas (negativos, outliers), estandarizar unidades ($\mu\text{g}/\text{m}^3$), enriquecer con país/ciudad.

GOLD `fact_calidad_aire_diaria` (AQI calculado), `dim_estacion`, `dim_ciudad`. Dashboard: ranking de ciudades más contaminadas, mapa de calor.

04 USGS Earthquakes — Sismos

earthquake.usgs.gov/fdsnws

Sin auth

Tiempo real

BRONZE Sismos del último día/semana en GeoJSON: magnitud, profundidad, coordenadas, tsunamis.

SILVER Parsear GeoJSON a tabular, clasificar por escala (leve/moderado/fuerte), asignar región por coordenadas.

GOLD `fact_sismos_diarios`, `dim_region`. Dashboard: mapa de sismos, distribución de magnitudes.

05 GitHub Events — Open Source

api.github.com

Sin auth (60 req/h)

Tiempo real

BRONZE Eventos públicos: PushEvent, PullRequestEvent, IssuesEvent, ForkEvent, etc.

SILVER Clasificar por tipo de evento, extraer lenguaje del repo, parsear actor, filtrar bots.

GOLD `fact_actividad_diaria`, `dim_lenguaje`, `dim_tipo_evento`. Dashboard: lenguajes más activos, ratio PRs/issues.

06 Citybikes — Bicicletas públicas

api.citybik.es/v2

Sin auth

Cada 2-5 min

BRONZE Snapshot de estaciones (EcoBici, Citi Bike...): bikes disponibles, slots vacíos, coordenadas, timestamp.

SILVER Enriquecer con barrio/zona por coordenadas, calcular ocupación, filtrar estaciones inactivas.

GOLD `fact_ocupacion_por_hora`, `dim_estacion`, `dim_zona`. Dashboard: estaciones más saturadas, uso por hora.

07 OpenSky — Tráfico aéreo

opensky-network.org/api

Sin auth (anónimo)

Cada 10 s

BRONZE Snapshot de aviones en vuelo: lat, lon, altitud, velocidad, rumbo, país de origen, indicativo.

SILVER Filtrar por región, clasificar fase de vuelo (ascenso/crucero/descenso por altitud), enriquecer con país/continente.

GOLD `fact_trafico_por_hora`, `dim_vuelo`, `dim_region`. Dashboard: mapa de vuelos activos, densidad por zona.

08 NASA FIRMS — Focos de incendio

firms.modaps.eosdis.nasa.gov/api/area

MAP_KEY gratis

Near real-time (~1 h)

BRONZE Detecciones de fuego activo (lat, lon, brillo, confianza, FRP, satélite, fecha) por bounding box de Argentina. Respuesta en CSV.

SILVER Filtrar por confianza, deduplicar detecciones entre satélites, clasificar intensidad por FRP/brillo, asignar provincia.

GOLD `fact_focos_diarios`, `dim_provincia`, `dim_satelite`. Dashboard: mapa de incendios activos, provincias más afectadas.

09 Transporte Buenos Aires

api-transporte.buenosaires.gob.ar

Registro gratis

Tiempo real (~30 s)

BRONZE Posiciones GPS de colectivos / subte vía GTFS-realtime (parsear el protobuf a tabular): línea, vehículo, lat/lon, velocidad, timestamp.

SILVER Filtrar por línea/zona, calcular velocidad y estado, enriquecer con el GTFS estático (nombre de línea, recorrido).

GOLD `fact_posiciones_por_hora`, `dim_linea`, `dim_franja_horaria`. Dashboard: mapa de unidades en vivo, horas pico.

⚠ **Más setup:** registrarse para las credenciales y parsear GTFS-realtime (protobuf). Para quienes quieran un desafío extra.

10 Where the ISS at? — ISS

api.wheretheiss.at/v1/satellites/25544

Sin auth

Tiempo real

BRONZE Snapshot de la posición de la ISS (lat, lon, altitud, velocidad, visibilidad día/noche, timestamp) en cada ingesta.

SILVER Determinar si está sobre océano o tierra / qué país por coordenadas, fase día/noche, deltas de posición entre snapshots.

GOLD `fact_paso_por_region`, `dim_region`. Dashboard: traza orbital en el mapa, % de tiempo sobre tierra vs océano.

i La más simple en datos: el valor está en acumular la trayectoria con el tiempo.