

# TP Final — Infra para Ciencia de Datos

---



Entrega: dom 15/11, 23:59



Presentación: jue 19/11

## 1 Objetivo

Construir un pipeline de datos **end-to-end** sobre **una API pública**, con arquitectura medallion. Orquestarlo con **Airflow**, guardarlo en **PostgreSQL** y mostrar un **dashboard sobre Gold** (todo containerizado).

## 2 Cómo se evalúa

### 1 Entrega y funcionamiento

Un `docker compose up` que levante todo (base, Airflow y dashboard), que el pipeline **empiece a correr solo**, sin activar DAGs a mano ni crear schemas manualmente: Bronze corre al levantar el stack y, cuando termina, dispara Silver y después Gold.

### 2 Cumplir la consigna

Las versiones y tecnologías pedidas: **Airflow 3.1.5** (imagen `apache/airflow:3.1.5`), arquitectura **Medallion** (Bronze → Silver → Gold) y **SQL** para las transformaciones, **dashboard** sobre las tablas Gold (**Star o Snowflake**), y **README del grupo**: integrantes y usuarios de GitHub, API elegida, modelo de datos, cómo levantarlo, y usuario y contraseña de Airflow.

### 3 Trabajo colaborativo en git

Commits de **distintos integrantes**, repartidos en el tiempo.

### 4 Presentación final

Tiempos y formas: 7 a 10 minutos, dinámica y clara. Qué problema eligieron, cómo lo resolvieron y a qué resultado llegaron.

---

**Adicional, para la nota individual:**

### 5 Participación durante la cursada

Las entregas de cada clase, en tu PR.

## 3 Cómo se entrega

1. **Usen el número de grupo** que ya tienen asignado ( `G01` , `G02` ...). Va en la rama, en la carpeta y en el título del PR.
2. Creen la rama `tpfinal/G<NN>` desde `main` , y la carpeta `TpFinal/grupos/G<NN>/` .
3. Abran un **PR** contra `main` , con título `TP Final - G<NN> - <API>` . En el cuerpo: integrantes (nombre + usuario de GitHub), API elegida e idea para Gold.

4. Trabajen en esa rama: **cada push actualiza el PR solo**.
5. **Entrega: domingo 15 de noviembre, 23:59** (hora Argentina). Vale **lo que esté en la rama** en ese momento: no hay que apretar ningún botón.

El `.env` del grupo **sí va al repo**, a propósito: así el stack levanta con un solo comando. Son credenciales de juguete ( `admin/admin` ).

**Si su API necesita una key, esa no se comparte.** Dejen la variable en el `.env` con un valor ficticio ( `MI_API_KEY=completar_con_tu_key` ) y **avísenlo en el README del grupo**: qué variable hay que completar, dónde se saca la key, y que va antes de levantar el stack.

## 4 La presentación final

**Jueves 19 de noviembre de 2026 · remota, por videollamada · 7 a 10 minutos** por grupo, con el dashboard corriendo. Muestren la idea del proyecto y el pipeline funcionando. Después, una ronda corta de **preguntas**.

### Cómo contarlos

La presentación tiene tres partes: **problema** → **enfoque** → **resultados**.

- **Problema:** el problema que seleccionaron, y por qué vale la pena resolverlo.
- **Enfoque:** qué y cómo hicieron para resolverlo — los datos, el pipeline y las decisiones que tomaron.
- **Resultados:** los resultados que obtuvieron — el dashboard y las conclusiones.

### Los 7 a 10 minutos

Una distribución posible, no obligatoria:

| 1 a 2 min                     | 3 a 4 min                           | 2 a 3 min                                                |
|-------------------------------|-------------------------------------|----------------------------------------------------------|
| el problema que seleccionaron | qué y cómo hicieron para resolverlo | los resultados que obtuvieron (dashboard y conclusiones) |

**Formato libre, pero descargable:** la presentación **se sube al campus**, así que tiene que quedar en **PDF o PPT**. **Entre 5 y 10 diapositivas**. No va al repo ni entra en el corte del 15/11: se puede subir hasta el momento de presentar.

### Tips

- Que sea **dinámico**.
- No hace falta que hablen todos, pero **todos tienen que estar listos para responder**.
- **Cámara prendida** durante la exposición.

## 5 Fuentes posibles

Elijan **una**. Todas se actualizan al menos cada hora. Pueden repetir API entre grupos, o proponer otra consultando con el docente.

**No valen APIs de crypto ni de exchanges:** CoinGecko es el ejemplo que usamos en clase.

💡 Las ideas por capa son **orientativas**, no requisitos.

### 01 Open-Meteo — Clima

[open-meteo.com](https://open-meteo.com)

Sin auth, sin límite

Cada hora

**BRONZE** Clima actual + forecast 7 días para N ciudades: temperatura, lluvia, humedad, viento.

**SILVER** Normalizar unidades (°C, km/h), separar forecast de medición real, sensación térmica.

**GOLD** `fact_clima_diario`, `dim_ciudad`, `dim_tiempo`. Dashboard: comparación entre ciudades, alertas de temperatura extrema.

### 02 OpenWeatherMap — Clima

[api.openweathermap.org](https://api.openweathermap.org)

API key gratis

Cada 10 min

**BRONZE** Clima actual + pronóstico 5 días para ciudades configuradas.

**SILVER** Parsear JSON anidado, extraer condiciones (nublado, lluvia, despejado), UTC → local.

**GOLD** `fact_pronostico_vs_real`, `dim_condicion_climatica`. Dashboard: precisión del pronóstico, patrones por estación.

### 03 OpenAQ — Calidad del aire

[api.openaq.org/v2](https://api.openaq.org/v2)

Sin auth

Cada hora

**BRONZE** Mediciones de PM2.5, PM10, CO, NO2, O3 por estación de monitoreo global.

**SILVER** Filtrar mediciones inválidas (negativos, outliers), estandarizar unidades (µg/m<sup>3</sup>), enriquecer con país/ciudad.

**GOLD** `fact_calidad_aire_diaria` (AQI calculado), `dim_estacion`, `dim_ciudad`. Dashboard: ranking de ciudades más contaminadas, mapa de calor.

### 04 USGS Earthquakes — Sismos

[earthquake.usgs.gov/fdsnws](https://earthquake.usgs.gov/fdsnws)

Sin auth

Tiempo real

**BRONZE** Sismos del último día/semana en GeoJSON: magnitud, profundidad, coordenadas, tsunamis.

**SILVER** Parsear GeoJSON a tabular, clasificar por escala (leve/moderado/fuerte), asignar región por coordenadas.

**GOLD** `fact_sismos_diarios`, `dim_region`. Dashboard: mapa de sismos, distribución de magnitudes.

## 05 GitHub Events — Open Source

api.github.com

Sin auth (60 req/h)

Tiempo real

**BRONZE** Eventos públicos: PushEvent, PullRequestEvent, IssuesEvent, ForkEvent, etc.

**SILVER** Clasificar por tipo de evento, extraer lenguaje del repo, parsear actor, filtrar bots.

**GOLD** `fact_actividad_diaria`, `dim_lenguaje`, `dim_tipo_evento`. Dashboard: lenguajes más activos, ratio PRs/issues.

## 06 Citybikes — Bicicletas públicas

api.citybik.es/v2

Sin auth

Cada 2-5 min

**BRONZE** Snapshot de estaciones (EcoBici, Citi Bike...): bikes disponibles, slots vacíos, coordenadas, timestamp.

**SILVER** Enriquecer con barrio/zona por coordenadas, calcular ocupación, filtrar estaciones inactivas.

**GOLD** `fact_ocupacion_por_hora`, `dim_estacion`, `dim_zona`. Dashboard: estaciones más saturadas, uso por hora.

## 07 OpenSky — Tráfico aéreo

opensky-network.org/api

Sin auth (anónimo)

Cada 10 s

**BRONZE** Snapshot de aviones en vuelo: lat, lon, altitud, velocidad, rumbo, país de origen, indicativo.

**SILVER** Filtrar por región, clasificar fase de vuelo (ascenso/crucero/descenso por altitud), enriquecer con país/continente.

**GOLD** `fact_trafico_por_hora`, `dim_vuelo`, `dim_region`. Dashboard: mapa de vuelos activos, densidad por zona.

## 08 NASA FIRMS — Focos de incendio

firms.modaps.eosdis.nasa.gov/api/area

MAP\_KEY gratis

Near real-time (~1 h)

**BRONZE** Detecciones de fuego activo (lat, lon, brillo, confianza, FRP, satélite, fecha) por bounding box de Argentina. Respuesta en CSV.

**SILVER** Filtrar por confianza, deduplicar detecciones entre satélites, clasificar intensidad por FRP/brillo, asignar provincia.

**GOLD** `fact_focos_diarios`, `dim_provincia`, `dim_satelite`. Dashboard: mapa de incendios activos, provincias más afectadas.

## 09 Transporte Buenos Aires

api-transporte.buenosaires.gob.ar

Registro gratis

Tiempo real (~30 s)

**BRONZE** Posiciones GPS de colectivos / subte vía GTFS-realtime (parsear el protobuf a tabular): línea, vehículo, lat/lon, velocidad, timestamp.

**SILVER** Filtrar por línea/zona, calcular velocidad y estado, enriquecer con el GTFS estático (nombre de línea, recorrido).

**GOLD** `fact_posiciones_por_hora`, `dim_linea`, `dim_franja_horaria`. Dashboard: mapa de unidades en vivo, horas pico.

⚠ **Más setup:** registrarse para las credenciales y parsear GTFS-realtime (protobuf). Para quienes quieran un desafío extra.

## 10 Where the ISS at? — ISS

api.wheretheiss.at/v1/satellites/25544

Sin auth

Tiempo real

**BRONZE** Snapshot de la posición de la ISS (lat, lon, altitud, velocidad, visibilidad día/noche, timestamp) en cada ingesta.

**SILVER** Determinar si está sobre océano o tierra / qué país por coordenadas, fase día/noche, deltas de posición entre snapshots.

**GOLD** `fact_paso_por_region`, `dim_region`. Dashboard: traza orbital en el mapa, % de tiempo sobre tierra vs océano.

**i La más simple en datos:** el valor está en acumular la trayectoria con el tiempo.